

LEMBAR KERJA MAHASISWA (LKM)

LK.8 Perancangan Project Data Science

Nama	: Ferdiansyah Saputra
Tanggal	: 6 Desember 2025
Kelas	: 5A
Judul Project : Pemetaan Prioritas Intervensi Penanganan Anak Tidak Sekolah Jenjang SD Menggunakan Algoritma K-Means Clustering	

A. Instruksi

Peserta diminta untuk merancang sebuah proyek Data Science yang berfokus pada permasalahan di bidang pendidikan. Rancangan proyek ini harus disusun secara sistematis berdasarkan metodologi CRISP-DM (Cross Industry Standard Process for Data Mining) yang mencakup enam tahapan utama, yaitu:

1. Business Understanding (Pemahaman Bisnis)
2. Data Understanding (Pemahaman Data)
3. Data Preparation (Persiapan Data)
4. Modeling (Pemodelan)
5. Evaluation (Evaluasi)
6. Deployment (Penerapan)

Pada setiap tahapan, peserta diharapkan dapat:

1. Menjelaskan tujuan dan fokus kegiatan pada tahap tersebut.
2. Menguraikan langkah-langkah yang dilakukan serta teknik atau metode yang digunakan.
3. Menjelaskan jenis dan sumber data yang diperlukan.
4. Menunjukkan hasil atau keluaran yang diharapkan dari tiap tahap.

Gunakan contoh kasus nyata atau permasalahan aktual di dunia pendidikan, seperti: Prediksi prestasi belajar siswa, Analisis tingkat kehadiran, Deteksi dini siswa berisiko tidak lulus, atau Rekomendasi pembelajaran adaptif berbasis data.

Hasil akhir dari tugas ini berupa dokumen rancangan proyek Data Science lengkap yang menggambarkan alur proses dari awal hingga implementasi model, serta menunjukkan bagaimana solusi berbasis data dapat memberikan manfaat nyata bagi peningkatan mutu pendidikan.

B. Format Perancangan

Tahapan CRISP-DM	Instruksi untuk Peserta	Rancangan Implementasi
1. Business Understanding (Pemahaman Bisnis)	1. Pilih konteks pendidikan (contoh: sekolah, universitas, pelatihan). 2. Identifikasi permasalahan yang dapat diselesaikan dengan data science.	1. Kebijakan Pendidikan Nasional (Pemerataan Akses) 2. Berdasarkan data tahun 2024, angka anak putus sekolah/tidak lanjut di jenjang SD masih

	3. Rumuskan tujuan bisnis (contoh: meningkatkan prestasi siswa, menurunkan tingkat ketidakhadiran).	bervariasi antar provinsi. Pemerintah sulit menentukan daerah mana yang harus diprioritaskan untuk alokasi dana bantuan khusus jika hanya melihat tabel data mentah yang panjang. 3. Tujuan bisnis diarahkan untuk mengelompokkan provinsi ke dalam tiga klaster prioritas. Prioritas Tinggi, Prioritas Sedang, dan Prioritas Rendah, sehingga pemerintah dapat mengidentifikasi wilayah dengan tingkat urgensi berbeda, sekaligus memberikan dasar yang lebih akurat dalam menyusun rekomendasi alokasi sumber daya agar distribusinya menjadi lebih efisien dan tepat sasaran.
2. Data Understanding (Pemahaman Data)	1. Jelaskan sumber data (contoh: data nilai siswa, absensi, data keluarga). 2. Sebutkan jenis data (numerik, kategorikal, teks, waktu). 3. Deskripsikan fitur dan target yang akan digunakan.	1. Dataset Publik Pusat Data dan Teknologi Informasi ("Jumlah anak tidak sekolah pada SD/ sederajat dikarenakan putus sekolah atau lulus tidak melanjutkan 2024"). 2. Tipe data dalam proyek ini terdiri dari data kategorikal berupa Wilayah (Nama Provinsi) dan Kode Wilayah, serta data numerik berupa kolom Jumlah yang menggambarkan total anak tidak sekolah pada setiap provinsi. 3. Fitur (X): Jumlah Anak Tidak Sekolah. Dan Target (Y): Tidak ada

		(Unsupervised Learning), outputnya adalah <i>Cluster ID</i> .
3. Data Preparation (Persiapan Data)	1. Tuliskan langkah pembersihan data: hapus duplikat, tangani nilai kosong, dan outlier. 2. Transformasi data: normalisasi, encoding data kategorikal.	1. Pembersihan data dilakukan dengan memeriksa keberadaan nilai kosong pada setiap provinsi serta memastikan bahwa kolom “Jumlah” memiliki tipe data Integer, bukan teks, sehingga proses analisis dan perhitungan jarak dapat berjalan dengan benar dan konsisten. 2. Transformasi data dilakukan dengan memilih fitur yang relevan melalui pembuangan kolom “No” dan “Kode Wilayah” karena tidak berpengaruh terhadap perhitungan jarak, kemudian dilanjutkan dengan proses scaling menggunakan Min-Max Scaler atau Z-Score untuk menormalkan rentang nilai yang sangat berbeda antarprovinsi, sehingga algoritma dapat menghitung jarak secara adil tanpa didominasi oleh provinsi dengan angka yang jauh lebih besar.
4. Modeling (Pemodelan)	1. Pilih algoritma yang sesuai (contoh: Decision Tree, Random Forest, Logistic Regression). 2. Jelaskan alasan pemilihan algoritma.	1. K-Means Clustering. 2. Pemilihan metode K-Means didasarkan pada tujuan proyek yang berfokus pada pengelompokan wilayah tanpa adanya label awal, sehingga pendekatan Unsupervised Learning menjadi paling sesuai. K-Means mampu bekerja

		secara efisien dengan memanfaatkan kedekatan jarak (magnitude) jumlah siswa putus sekolah, sehingga dapat memisahkan secara jelas provinsi yang memiliki tingkat permasalahan tinggi dan rendah, sekaligus memberikan struktur segmentasi yang lebih terukur dan mudah dianalisis.
5. Evaluation (Evaluasi)	Pilih metode evaluasi yang akan digunakan misalkan menggunakan cross-validation atau confusion matrix.	Metode evaluasi menggunakan Elbow Method dan Silhouette Score, di mana Elbow Method digunakan untuk menentukan jumlah kluster terbaik seperti apakah pembagian 3, 4, atau 5 kelompok prioritas paling optimal, sedangkan Silhouette Score digunakan untuk menilai kerapian dan keterpisahan kluster yang terbentuk, dengan nilai yang semakin mendekati 1 menunjukkan kualitas pemisahan antar kelompok yang semakin baik.
6. Deployment (Penerapan / Implementasi)	Buat rancangan deploymentnya tampilan interface nya	Rancangan dashboard berupa peta geografis interaktif Indonesia yang menampilkan sebaran ATS, dengan setiap provinsi diberi warna sesuai kluster merah untuk prioritas tinggi, kuning untuk prioritas sedang, dan hijau untuk prioritas rendah serta dilengkapi fitur hover yang menampilkan tooltip berisi informasi jumlah anak putus sekolah dan rekomendasi tindakan seperti penambahan program Sekolah Terbuka.